

UNIVERSIDADE DE SÃO PAULO
ESCOLA POLITÉCNICA
PROGRAMA DE EDUCAÇÃO CONTINUADA (PECE)
ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL

Inteligência Artificial para Liberação Automática de Documentos de Faturamento

Machine Learning aplicado ao processo Meter-to-Cash

Disciplina: IAD-002 Negócios com Inteligência Artificial
Professora: Patrícia Pampanelli

Autores:

Anderson Eduardo Santos Cardoso
Anthony Moura Carvalho
César Jesus Silva
Denis Henrique Kulh
Igor Canan Kfourri

São Paulo
2026

Inteligência Artificial para Liberação Automática de Documentos de Faturamento com Exceção

Business Case Executivo: Machine Learning Aplicado ao Ciclo Meter-to-Cash

SEGMENTO UTILITIES: ENERGIA • GÁS • ÁGUA

1. O Cenário Atual e o Desafio Operacional

No processo de faturamento das distribuidoras de Utilities, milhares de documentos de faturamento são rotineiramente retidos e direcionados para tratamento de exceções. Esse bloqueio preventivo ocorre para mitigar riscos comerciais e regulatórios, sendo disparado por regras de negócio complexas, tais como:

- **Anomalias de consumo:** Desvios abruptos no histórico do cliente (sazonalidade, picos ou quedas).
- **Regras tarifárias complexas:** Mudanças de grupo, subsídios ou impostos dinâmicos.
- **Inconsistências cadastrais:** Divergências entre dados físicos da instalação e o registro comercial.
- **Validações regulatórias:** Critérios estritos determinados pelos órgãos reguladores do setor.

Fluxo Operacional Atual:

Documento Gerado → Retenção em Exceção
→ Análise Manual por Especialista →
Liberação ou Correção.

Impactos Críticos: Alto esforço operacional, gargalos severos no fechamento mensal, custos administrativos elevados e forte dependência de conhecimento especializado.

O DESAFIO CENTRAL DE PROJETO: Confiabilidade dos Dados para Treinamento

O principal obstáculo para a eficiência de um modelo preditivo não reside nos algoritmos, mas na **qualidade do dado histórico**. Para que o modelo aprenda corretamente, é imprescindível contar com um histórico de dados saneado, onde as ações passadas (liberações legítimas vs. correções reais) estejam devidamente rotuladas e livres de ruídos cadastrais. Dados inconsistentes geram um aprendizado enviesado, comprometendo a segurança da automação.

2. A Oportunidade Estratégica com Inteligência Artificial

A aplicação de Inteligência Artificial inverte a lógica reativa do processo. Em vez de analisar manualmente cada exceção gerada, o ecossistema passa a responder de forma preditiva a uma pergunta fundamental de negócio:

"Dado que um documento já está em exceção, qual é a real probabilidade de ele ser liberado sem a necessidade de intervenção ou correção?"

O modelo de Machine Learning analisa múltiplas variáveis em tempo de execução para calcular essa probabilidade, baseando-se no comportamento histórico de cenários semelhantes, conforme detalhado a seguir:

Variáveis de Entrada Analisadas

- **Dados de Consumo:** Consumo atual, histórico plurianual e fatores de sazonalidade climática/econômica.
- **Dados de Faturamento:** Valor faturado, desvios padrão do faturamento médio e histórico de ocorrências de exceção da instalação.
- **Dados Cadastrais:** Classe de consumo (Residencial, Comercial, Industrial), grupo tarifário e especificidades técnicas da instalação.
- **Dados Operacionais:** Código do motivo da exceção e correlação com resultados de casos similares recentes.

Conceito de Aprendizado

A IA mapeia o comportamento dos especialistas frente a casos passados. Ela correlaciona as características técnicas e comerciais do documento com a decisão final tomada no passado (liberação direta ou modificação dos valores).

Objetivo Final: Direcionar faturas de altíssima previsibilidade e baixo risco para a liberação em lote automática, isolando os casos genuinamente críticos para a mesa dos analistas.

3. Arquitetura de Integração e Modelagem Customizada

A abordagem defendida neste plano contorna as limitações de ferramentas genéricas. O ecossistema padrão da SAP oferece cenários de Machine Learning embarcados que servem predominantemente como *templates* ou exemplos conceituais simples. Para obter resultados expressivos e escaláveis no volume de uma distribuidora de Utilities, é necessária uma estratégia focada em **modelos customizados**.

A Função Estratégica da SAP: Consumo de Dados em Larga Escala

A plataforma SAP atua como o motor centralizador e integrador. Ela disponibiliza ferramentas robustas de conectividade para que sistemas especialistas externos consumam os dados transacionais em tempo real e de forma segura. O cliente ganha a liberdade de customizar e treinar modelos avançados externamente, aplicando algoritmos sob medida que maximizam a acurácia dos resultados e suportam o volume massivo do faturamento de Utilities.

Os modelos avaliados e refinados para esta operação incluem:

- **Random Forest:** Excelente para lidar com relações não lineares e múltiplos dados cadastrais categóricos.
- **Gradient Boosting (XGBoost/LightGBM):** Alta performance e precisão para predição de scores baseados em tendências e desvios de consumo.
- **Regressão Logística:** Utilizada como linha de base (baseline) para calibração inicial e validação da interpretabilidade estatística.

4. Matriz de Decisão e Fluxo Inteligente

A operação passa a ser regida por faixas de confiança probabilística, automatizando a esteira de faturamento e introduzindo uma camada de triagem inteligente:

Probabilidade Calculada	Tratamento Operacional	Impacto Prático no Processo
> 90% de Confiança	LIBERAÇÃO AUTOMÁTICA	A fatura é aprovada pelo sistema instantaneamente, sem toque humano, reduzindo o tempo de emissão.
70% a 90% de Confiança	REVISÃO SIMPLIFICADA	Agrupamento em lotes homogêneos para validação rápida e semi-automatizada pelos analistas.
< 70% de Confiança	ANÁLISE MANUAL	Direcionamento prioritário para os especialistas investigarem fraudes, erros graves ou falhas de leitura.

Exemplo de Aplicação Prática:

- *Documento A (96% de probabilidade):* Identificado como uma oscilação comum e recorrente de perfil sazonal. **Ação:** Liberado automaticamente.
- *Documento B (84% de probabilidade):* Desvio tarifário leve por mudança de faixa. **Ação:** Enviado para aprovação simplificada em um clique.
- *Documento C (23% de probabilidade):* Queda abrupta inexplicável de consumo sem padrão similar. **Ação:** Retido para fiscalização em campo ou auditoria manual interna.

5. Geração de Valor e Visão de Futuro

A transição do modelo reativo-manual para o modelo preditivo orientado a dados gera eficiência imediata para a distribuidora de Utilities, otimizando o ciclo *Meter-to-Cash* de ponta a ponta.

Até 60% Redução de Esforço Manual Eliminação de análises redundantes em faturas recorrentes e seguras.	2.5x Velocidade no Ciclo Redução drástica no tempo de retenção física de faturas legítimas.	Alta Valorização do Especialista Foco da equipe técnica em desvios complexos e prevenção de perdas reais.
--	---	---

Conclusão e Próximos Passos

A implementação deste business case permite transformar o setor de faturamento de um centro de custos operacional e reativo em uma unidade inteligente, escalável e de alto desempenho. Ao utilizar o SAP estrategicamente como plataforma agregadora e consumidora de dados para impulsionar modelos preditivos customizados, a companhia blinda sua receita, elimina gargalos operacionais crônicos e garante total aderência às metas regulatórias de eficiência do mercado de energia, gás e água.

ANEXO I - CANVAS

Machine Learning Canvas | IA para Liberação Automática de Documentos de Faturamento com Exceção

Utilities - Energia, Gás e Água | Processo Meter-to-Cash

PREDIÇÕES		OBJETIVO / PROPOSTA DE VALOR	APRENDIZAGEM	
Decisões > 90% confiança: liberação automática da fatura, sem toque humano. 70% a 90%: revisão simplificada em lote homogêneo ou aprovação rápida. < 70%: análise manual por especialista, com prioridade por risco e impacto. - Sempre manter trilha de auditoria, justificativa do score e bloqueio para casos críticos.	ML Task - Classificação supervisionada binária com score probabilístico. - Input: documento de faturamento já em exceção + contexto de consumo, faturamento, cadastro e operação. - Output: probabilidade de liberação sem correção manual + faixa de tratamento operacional. - Alvo de treino: liberado sem correção vs. corrigido, reprocessado ou retido.	Objetivo - O quê: prever a probabilidade de um documento em exceção ser liberado sem intervenção ou correção manual. - Por quê: reduzir gargalos no fechamento, esforço operacional e custo administrativo, preservando receita e compliance. - Quem: equipes de faturamento, especialistas Meter-to-Cash, gestores de operação, auditoria e áreas regulatórias. - Valor: transformar uma fila única em triagem inteligente por risco, liberando casos previsíveis e isolando desvios complexos.	Fontes de Dados - SAP Utilities: documentos de faturamento, motivos de exceção, status de retenção/liberação e histórico de correções. - Medição/VEE: leitura atual, histórico plurianual, consumo calculado, sazonalidade e método de coleta. - Cadastro: instalação, classe de consumo, grupo tarifário, características técnicas e contrato. - Operação: decisões passadas dos especialistas, retrabalho, reprocessamentos e logs de exceção. - Externas opcionais: clima, calendário, feriados, eventos sazonais e marcos regulatórios.	Coletando Dados - Extrair histórico saneado e rotulado por camada de dados segura conectada ao SAP. - Criar label operacional: liberado sem correção vs. corrigido, reprocessado ou retido. - Capturar novas decisões dos analistas como feedback contínuo do modelo. - Governança: remover ruídos cadastrais, duplicidades, erros preexistentes e dados sem rastreabilidade.
Quando e como fazer previsões - Executar após validações ERP/VEE e geração da exceção, antes da emissão final. - Rodar em batch no fechamento mensal e, quando necessário, near-real-time para filas críticas. - Recalcular quando houver nova leitura, correção cadastral, alteração de regra ou mudança tarifária. - Priorizar filas por risco, previsibilidade, valor financeiro e prazo regulatório.	Avaliação Offline - Separar treino/teste por janela temporal para simular o fechamento real. - Métricas: ROC-AUC, PR-AUC, precisão/recall por faixa, matriz de confusão, calibração/Brier. - Critério crítico: minimizar falso positivo de liberação automática. - Validar impacto financeiro, redução de esforço e SLA em piloto controlado antes do deploy.		Features (Variáveis) - Desvio do consumo atual contra histórico, média sazonal e perfil de instalação. - Valor faturado, variação contra média e histórico de desvios/exceções. - Motivo da exceção, recorrência e resultado recente de casos similares. - Classe de consumo, grupo tarifário, instalação, método de leitura e características técnicas. - Idade da fila, frequência de correções anteriores e impacto financeiro estimado.	Construindo o Modelo - Baseline interpretável: regressão logística. - Modelos candidatos: Random Forest e Gradient Boosting para relações não lineares e variáveis categóricas. - Calibrar thresholds com negócio: >90%, 70-90%, <70%. - Retreinar mensal/trimestralmente ou após mudanças de regra, tarifa, cadastro ou processo. - Deploy com explainability, versionamento, monitoramento de drift e rollback.
Avaliação Online e Monitoramento - Taxa de auto-liberação segura por faixa de confiança. - Redução de esforço manual, tempo médio na fila e velocidade do ciclo Meter-to-Cash. - Falso positivo de liberação, refaturamento, contestação, reclamações e alertas regulatórios. - Drift de dados/modelo, calibração do score e qualidade dos labels novos. - ROI: horas economizadas, custo evitado, receita preservada e aderência ao fechamento mensal.				